Université de Strasbourg

Traduction automatique
Transformers

Enzo Doyen

enzo.doyen@unistra.fr

2025-11-16

🕮 Plan

I. Détails sur l'architecture Transformer

II. Transformers pour la traduction automatique

III. Mise en pratique

I. Détails sur l'architecture Transformer

Réseaux de neurones récurrents

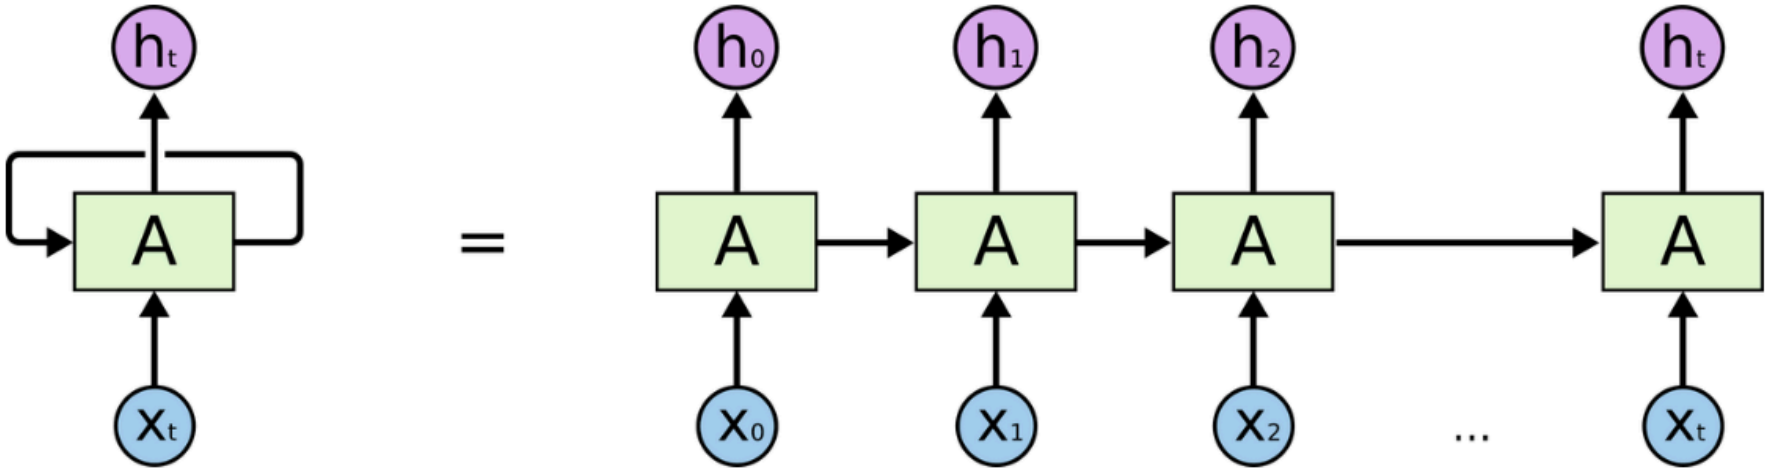

Source : https://colah.github.io/posts/2015-08-Understanding-LSTMs/

Limites des RNN

- **Traitement séquentiel** : les RNN traitent les entrées une par une, ce qui rend l'entrainement long.
  - Ce faisant, parallélisation impossible.
- **Problème du *vanishing gradient*** : sur les séquences longues, le modèle ne parvient plus à capturer les informations pertinentes vues en début de séquence.

Architecture Transformer

Transformer : type d'architecture introduit par Vaswani et al. (2017).

Abandonne complètement les RNN/ CNN et utilise uniquement des mécanismes d'attention pour encoder les séquences.

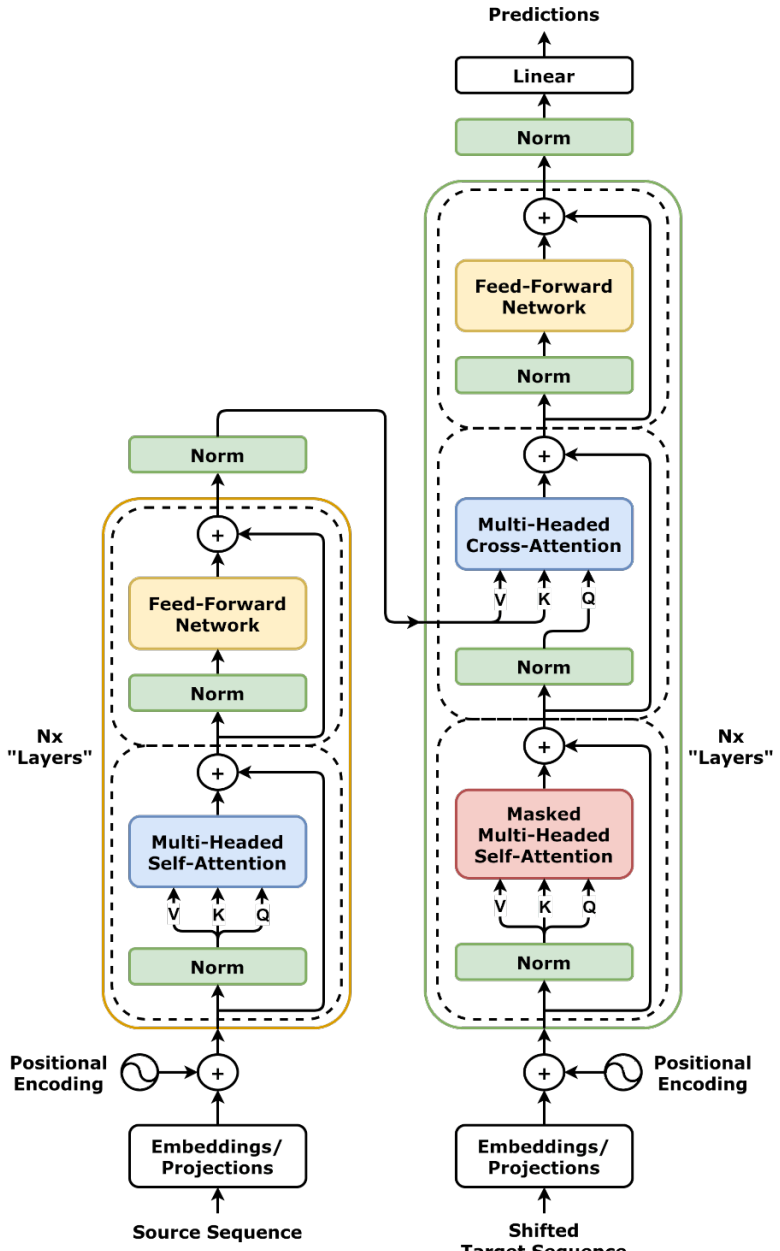

Architecture Transformer

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez*†
University of Toronto
aidan@cs.toronto.edu

Łukasz Kaiser*
Google Brain
lukaszkaiser@google.com

Illia Polosukhin*
illia.polosukhin@gmail.com

Architecture Transformer : types de modèles

- **Modèles encodeurs** : encodent la séquence d'entrée et produisent une représentation de celle-ci.
  - Utilisés pour des tâches de classification, d'analyse de sentiments, etc. (BERT, RoBERTa, DistilBERT...)
- **Modèles décodeurs (auto-régressifs)** : génèrent une séquence de sortie à partir d'une représentation d'entrée.
  - Utilisés pour des tâches de génération de texte (GPT, Llama...)
- **Modèles encodeurs-décodeurs (séquence-à-séquence)** : combinent les deux précédents pour des tâches de traduction, de résumé, etc. (T5, BART...)

Source : Luke Ditria

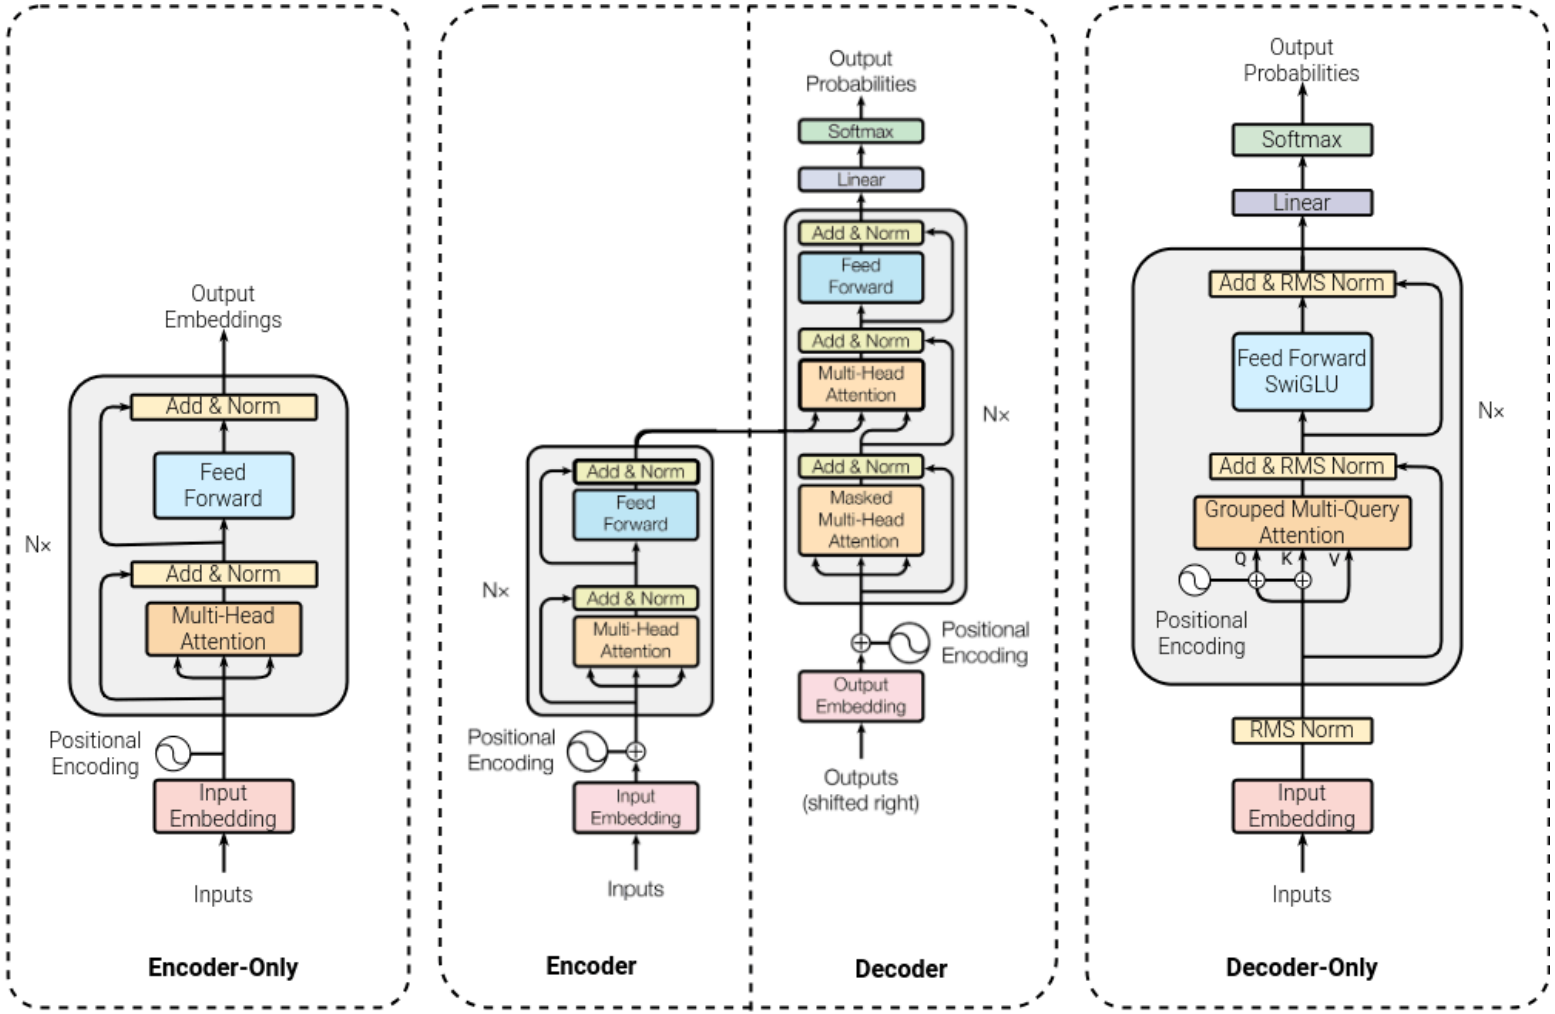

BERT
(Devlin et al., 2018)

Original Transformer
(Vaswani et al., 2017)

LLaMA
(Touvron et al., 2023)

Architecture Transformer : performances en traduction (encodeur-décodeur)

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	**$3.3 \cdot 10^{18}$**	
Transformer (big)	**28.4**	**41.8**	$2.3 \cdot 10^{19}$	

Source : **Vaswani et al. (2017)**

Architecture Transformer : couches d'encodage et de décodage

- L'architecture Transformer se base sur le cumul de N couches (généralement, $N = 6$).
- Ce cumul de couches permet au modèle de revoir plusieurs fois la séquence d'entrée et de la transformer en une représentation plus riche.
- Cela implique aussi une puissance de calcul plus importante.

Architecture Transformer : positionnement des tokens

- L'architecture Transformer ne traite pas les entrées de manière séquentielle (contrairement aux RNN qui le font token par token). À la place, elle traite tous les tokens du texte en entrée simultanément.
- Cela implique l'ajout d'informations de position aux tokens pour savoir où ils se situent dans la séquence.
- Utilisation de **couches d'encodage de position** (*position encoding layers*) pour ajouter ces informations.

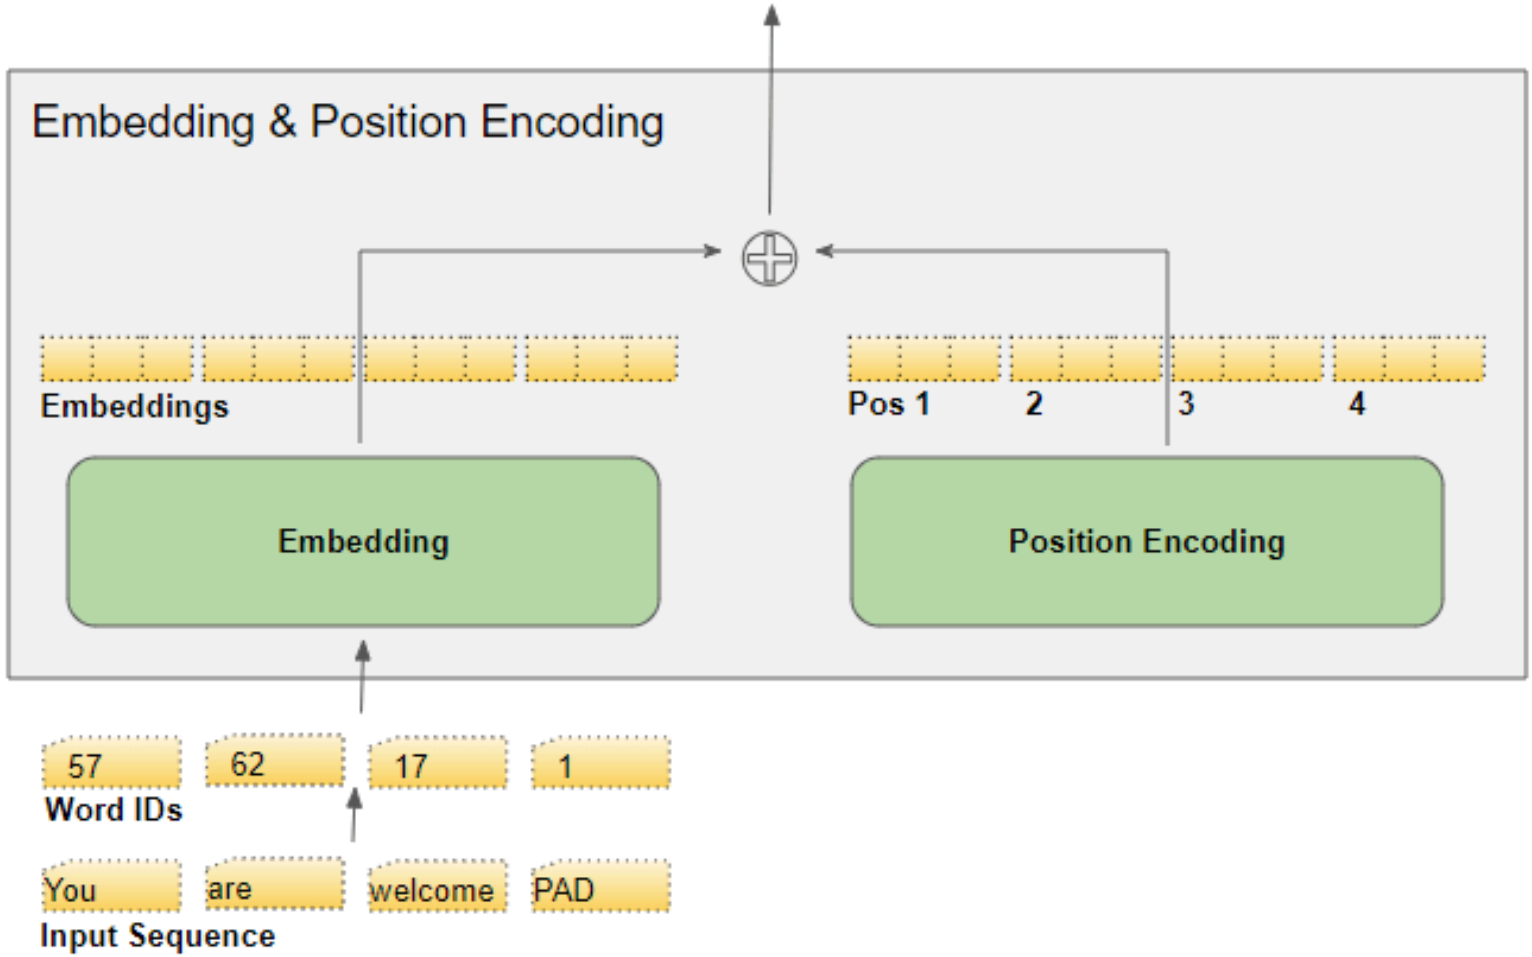

Source : https://towardsdatascience.com/transformers-explained-visually-part-2-how-it-works-step-by-step-b49fa4a64f34/

Architecture Transformer : mécanisme d'autoattention (*self-attention*)

- Mécanisme qui permet au modèle de donner des poids à chacune des différentes parties de la séquence d'entrée.
- Permet de capturer les relations entre les mots, même s'ils sont éloignés dans la séquence.

Arch. Transformer : mécanisme d'autoatt.

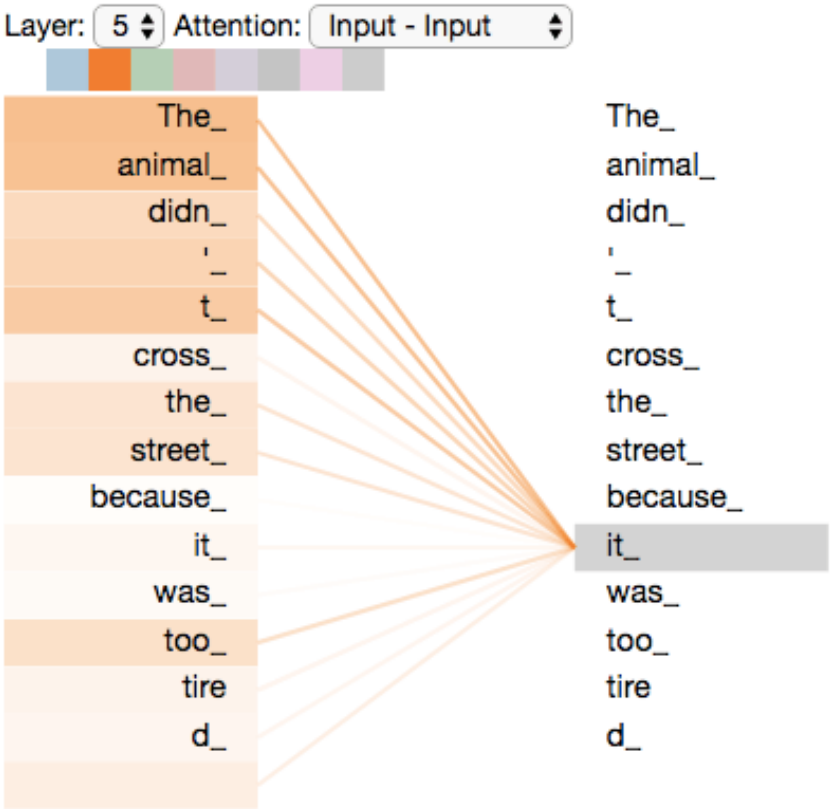

Source

Architecture Transformer : mécanisme d'autoattention (*self-attention*)

- Repose sur trois matrices pour chaque token : *queries* (Q), *keys* (K) et *values* (V).
- Ces matrices sont utilisées pour calculer combien d'attention un token doit porter à un autre dans la séquence, et quelles valeurs il doit en extraire.

Architecture Transformer : mécanisme d'autoattention (*self-attention*)

Reprenons notre exemple précédent :

« The animal didn't cross the street because it was too tired. »

Si nous voulons savoir à quoi le mot « it » fait référence :

- le vecteur Q du mot « it » est comparé aux vecteurs K de tous les autres mots de la phrase.
- le token avec le vecteur K le plus similaire au vecteur Q de « it » est « animal ».
- la valeur V associée à « animal » est extraite et utilisée pour enrichir la représentation de « it ».

Architecture Transformer : mécanisme d'autoattention (*self-attention*)

- Repose sur trois matrices pour chaque token : *queries* (Q), *keys* (K) et *values* (V).
- Ces matrices sont utilisées pour calculer combien d'attention un token doit porter à un autre dans la séquence, et quelles valeurs il doit en extraire.

$$\mathrm{Attention(Q,\ K,\ V)} = \mathrm{softmax}\left(\frac{\mathrm{QK}^T}{\sqrt{d_k}}\right)V$$

^{T} : matrice transposée

d_k : dimension des matrices Q et K

Architecture Transformer : *multi-head attention*

- L'architecture Transformer n'utilise pas une seule couche d'autoattention, mais plusieurs couches en parallèle (*multi-head attention*).
- Le mécanisme d'autoattention est appliqué plusieurs fois en parallèle, avec des poids différents pour chaque « tête » (*head*), ce qui permet au modèle de capturer différentes relations entre les tokens.

Architecture Transformer : *multi-head attention*

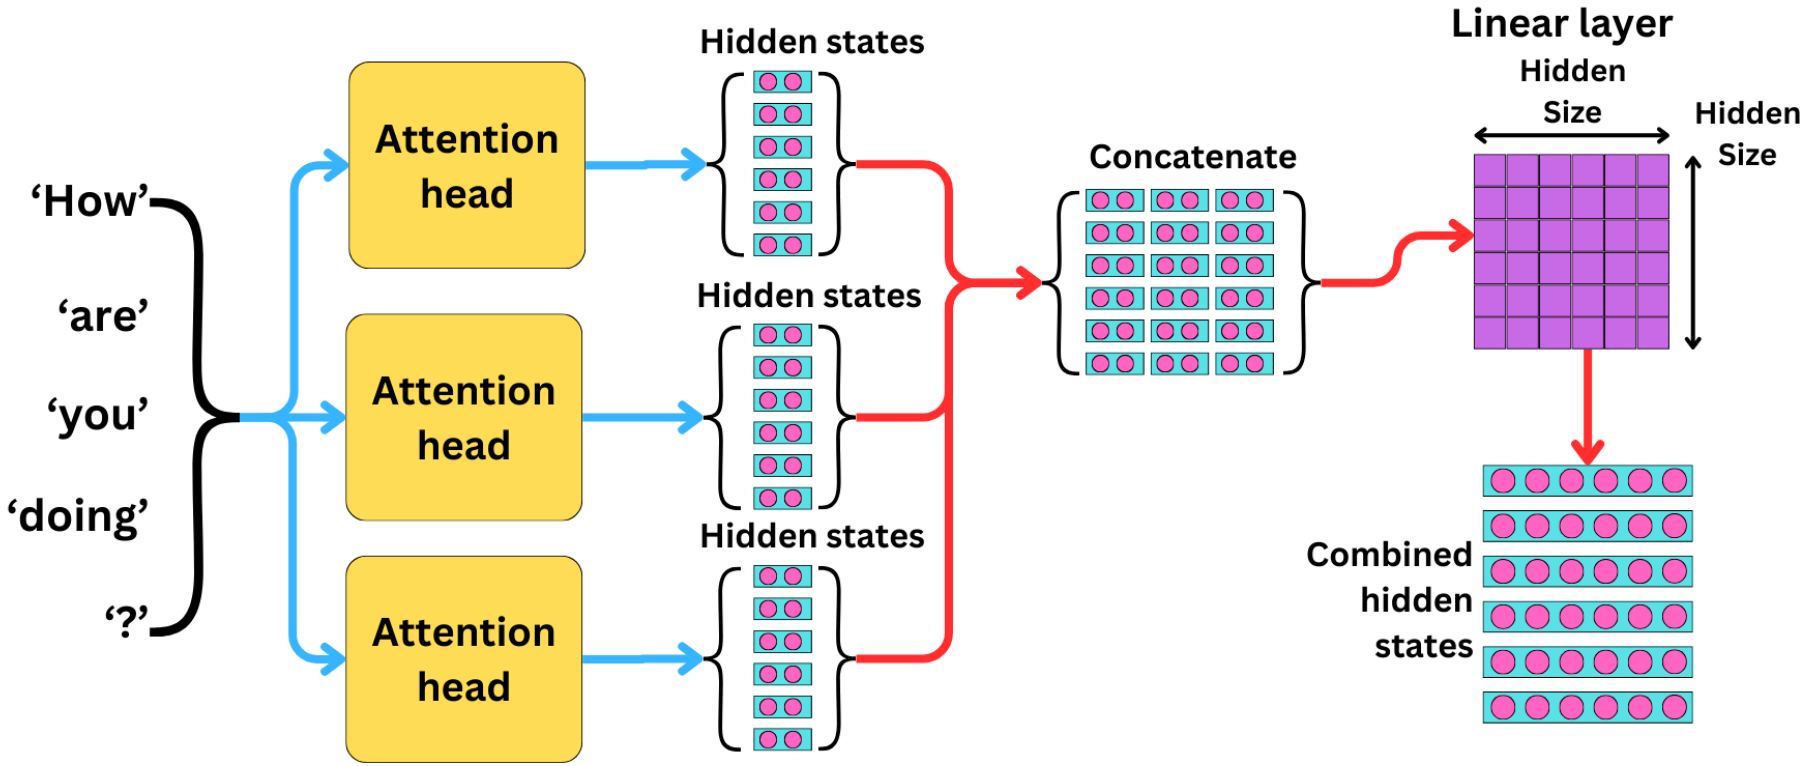

Source : https://newsletter.theaiedge.io/p/the-multi-head-attention-mechanism

II. Transformers pour la traduction automatique

Architecture Transformer : traduction automatique

- Pour une tâche de traduction automatique, l'architecture Transformer est utilisée comme un modèle encodeur-décodeur.
- Le modèle encodeur transforme la séquence d'entrée (phrase source) en une représentation riche ; le modèle décodeur utilise cette représentation pour générer la séquence de sortie (phrase cible).
- En particulier, le **mécanisme d'attention** vu précédemment permet d'utiliser le contexte de la phrase source pour enrichir sa représentation, et ainsi produire une meilleure traduction.
- **Animation d'exemple pour l'encodage/décodage pour une tâche de traduction** (Google AI Blog).

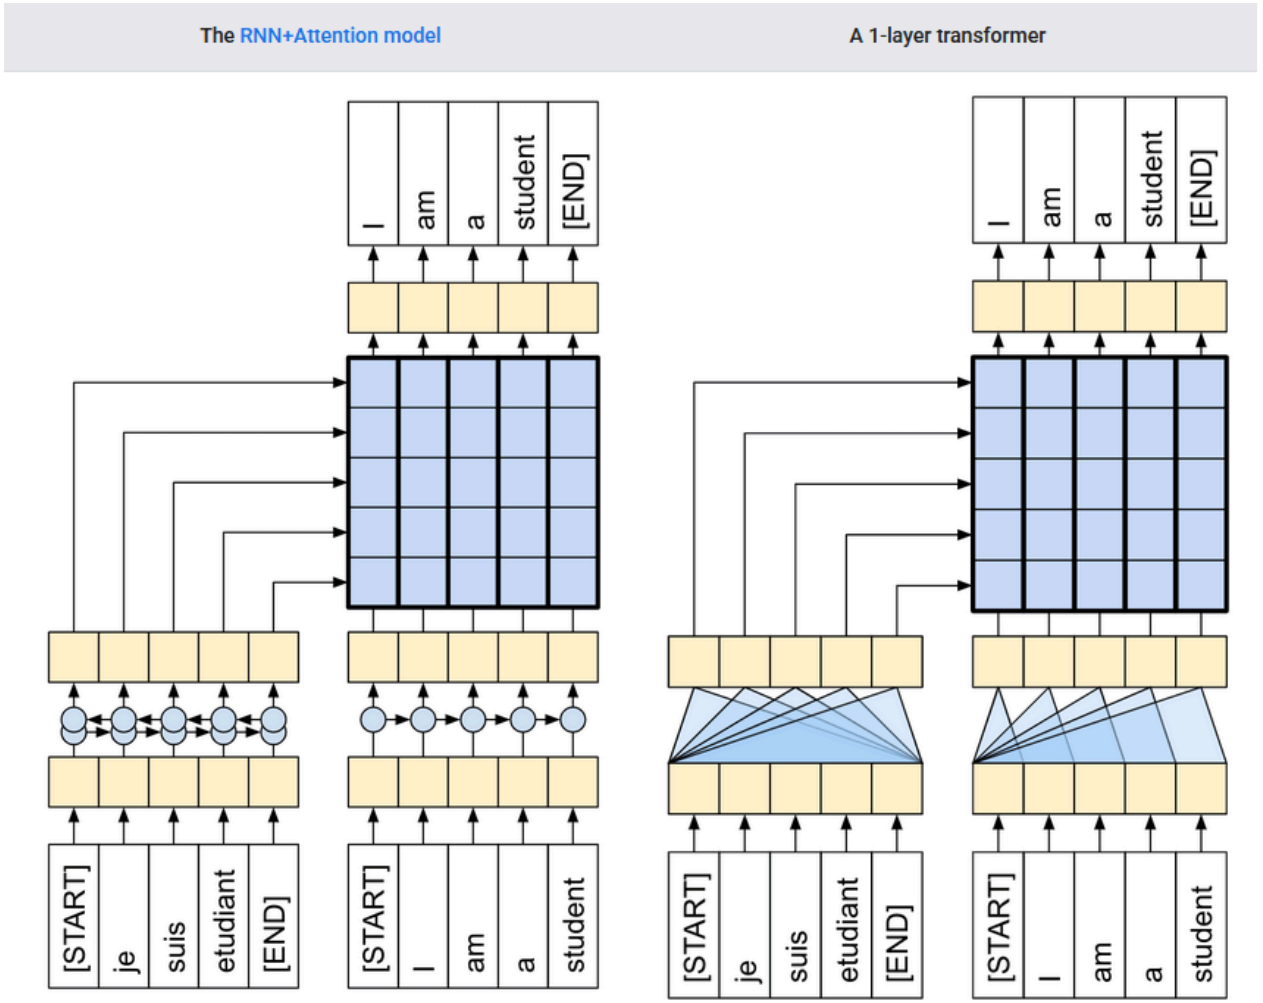

Différence RNN/Transformer pour la traduction

Source : **https://www.tensorflow.org/text/tutorials/transformer**

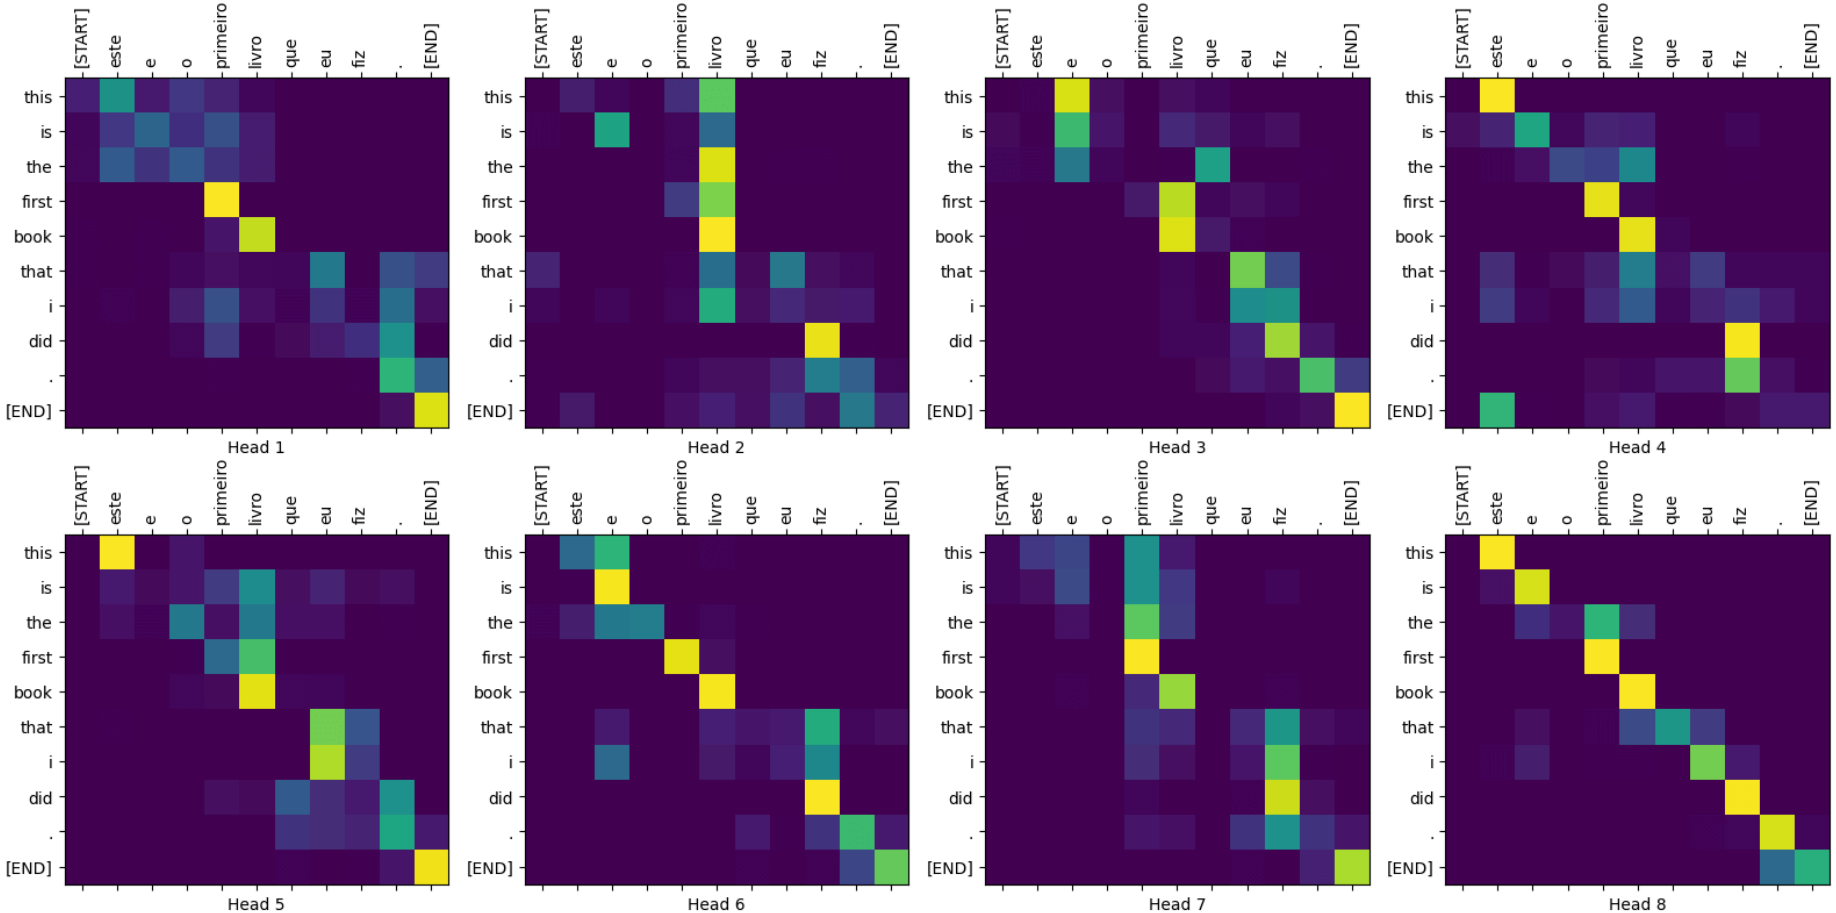

Représentation des *attention heads* pour une tâche de traduction

Source : **https://www.tensorflow.org/text/tutorials/transformer**

Préentrainement de modèles (*pretraining*)

- Les modèles Transformer sont souvent **préentrainés** sur de grandes quantités de données non étiquetées avant d'être ajustés (*fine-tuned*) pour des tâches spécifiques.
- Le préentrainement permet au modèle d'apprendre des représentations générales du langage, ce qui améliore ses performances sur des tâches spécifiques, y compris la traduction automatique.
- Idée initialement développée par **Dai et Le (2015)** sous le nom de *semi-supervised sequence learning*, mais véritablement mise en place par l'arrivée de l'architecture Transformer et le développement de BERT (*Bidrectional Encoder Representations from Transformers*) par **Devlin et al. (2018)**, et de GPT-2 (*Generative Pre-trained Transformer 2*) par **Radford et al. (2019)**.

Préentrainement de modèles (*pretraining*)

- Utilisation de grandes quantités de données non étiquetées pour préentrainer le modèle (livres, articles, sites Web, etc.) : tâche non supervisée.
- Différents objectifs de préentrainement pour que le modèle apprenne des représentations du langage :
  - **Causal Language Modeling** (CLM) : prédit le prochain mot dans une séquence, en utilisant les mots précédents comme contexte (GPT-2).
  - **Masked Language Modeling** (MLM) : masque certains tokens dans la séquence et demande au modèle de prédire ces tokens masqués (BERT).
  - **Denoising** : masque ou modifie certains tokens dans la séquence et demande au modèle de prédire la séquence originale (T5, BART).

Préentrainement de modèles : CLM (GPT-2)

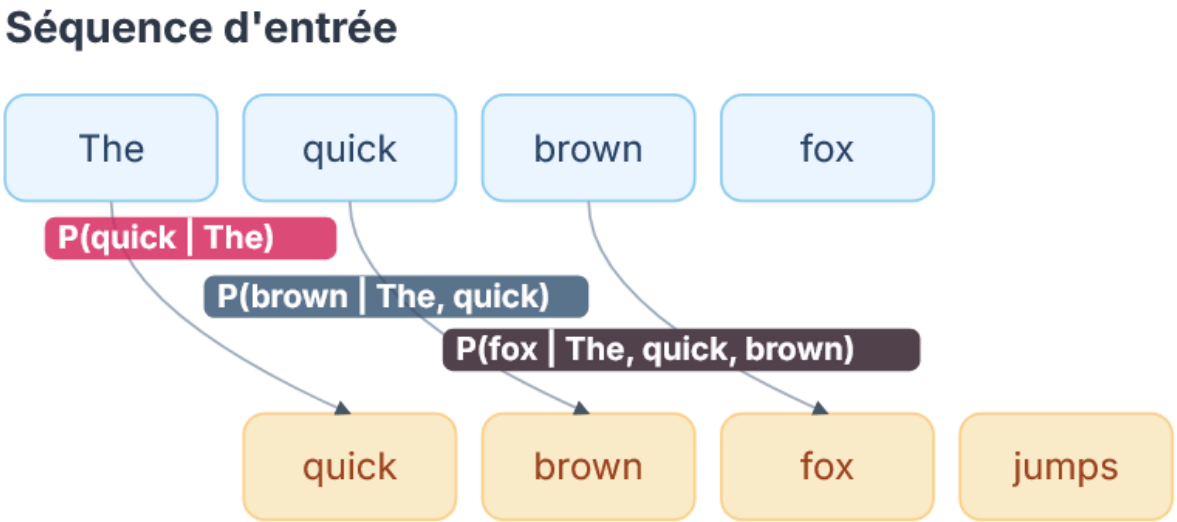

$$= \prod_{\mathrm{t}=1}^{n} P(w_t \mid \mathrm{w}_{<t})$$

Préentrainement de modèles : MLM (BERT)

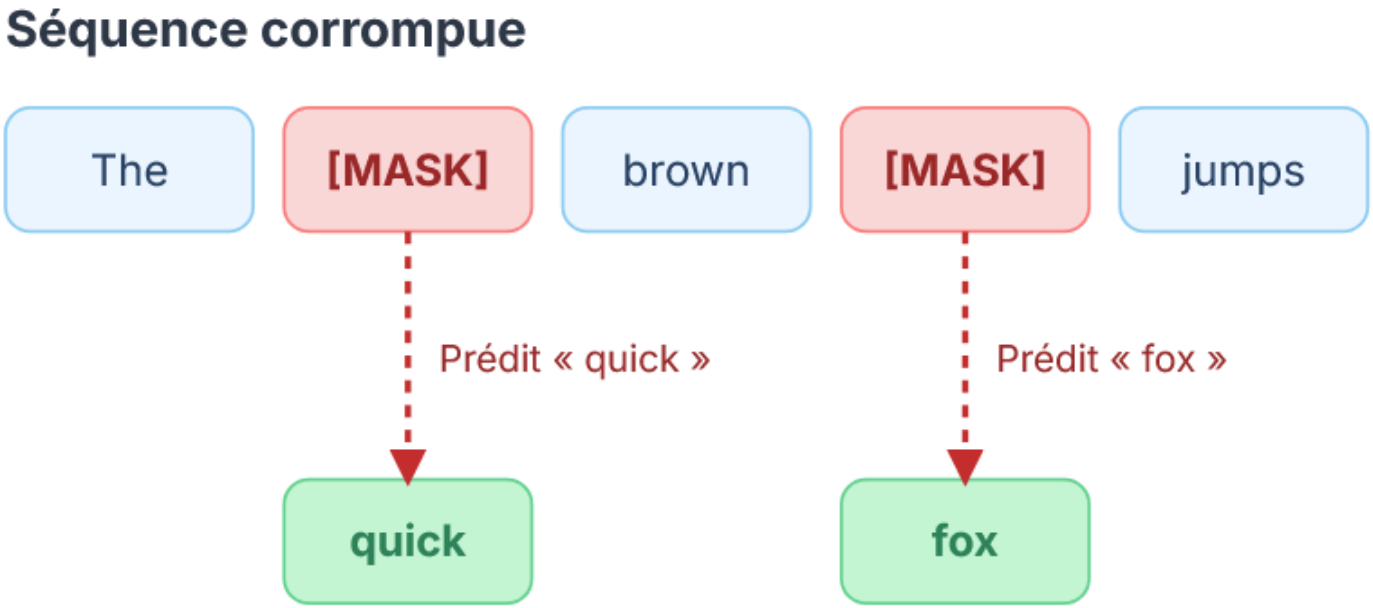

Préentrainement de modèles : MLM (BERT)

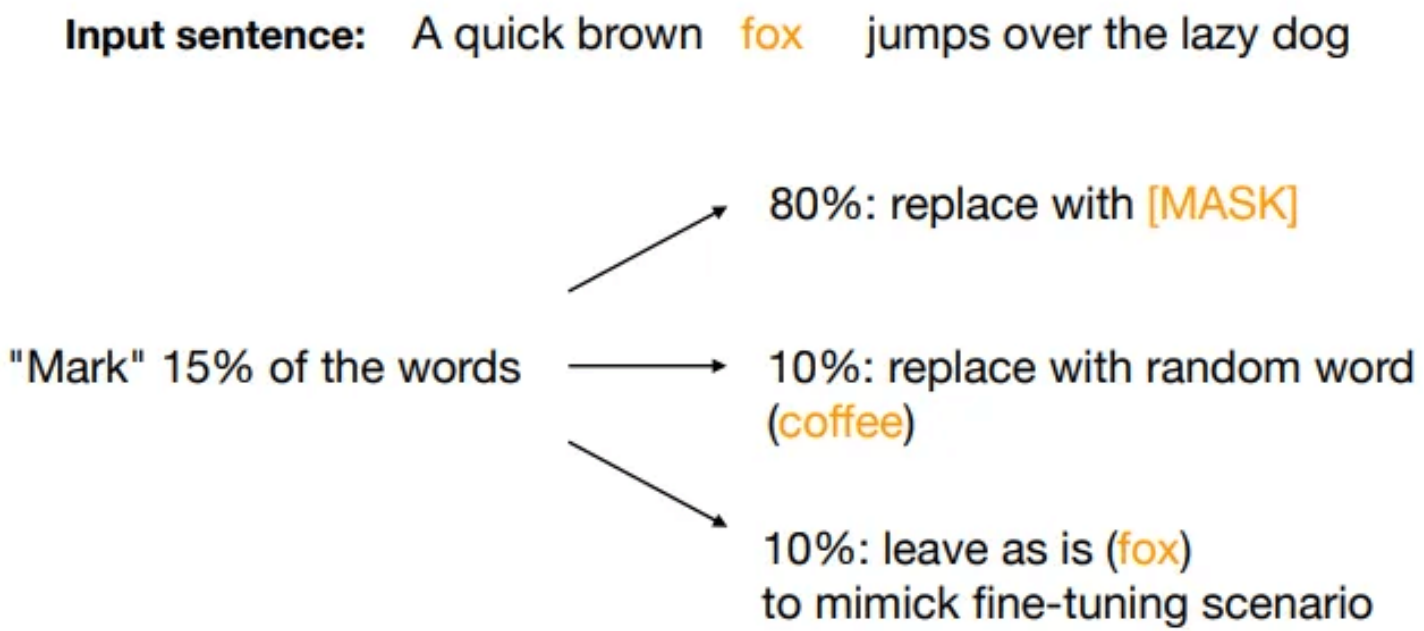

Source : https://medium.com/@zaiinn440/a-comparative-analysis-of-llms-like-bert-bart-and-t5

Préentrainement de modèles : denoising (T5)

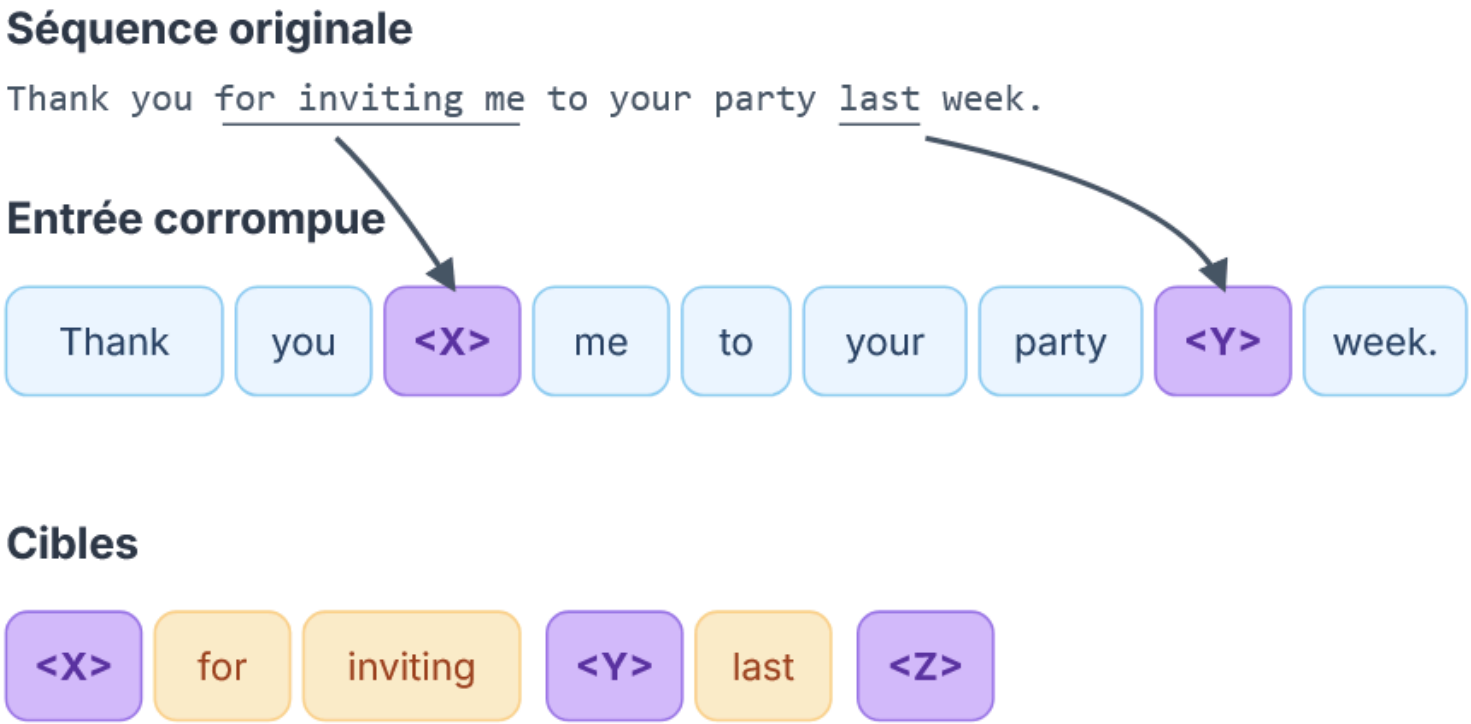

Préentrainement de modèles : denoising (T5)

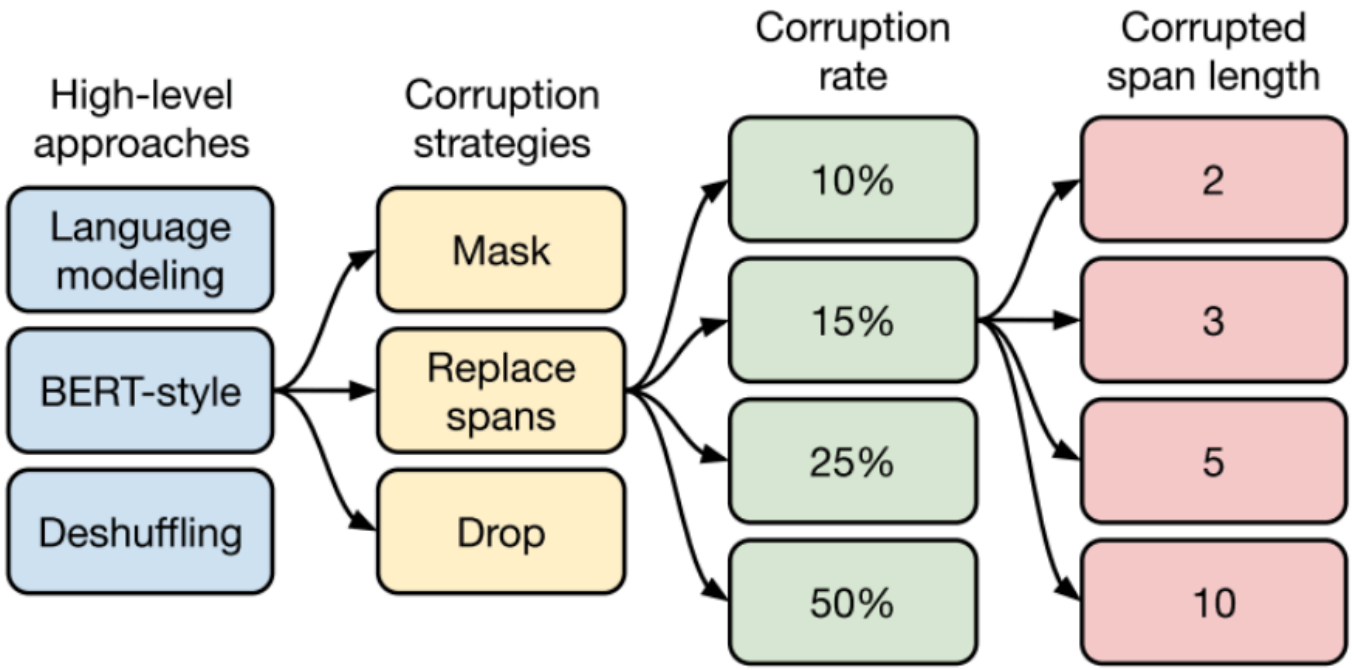

Source : **Raffel et al. (2020)**

Préentrainement de modèles : denoising

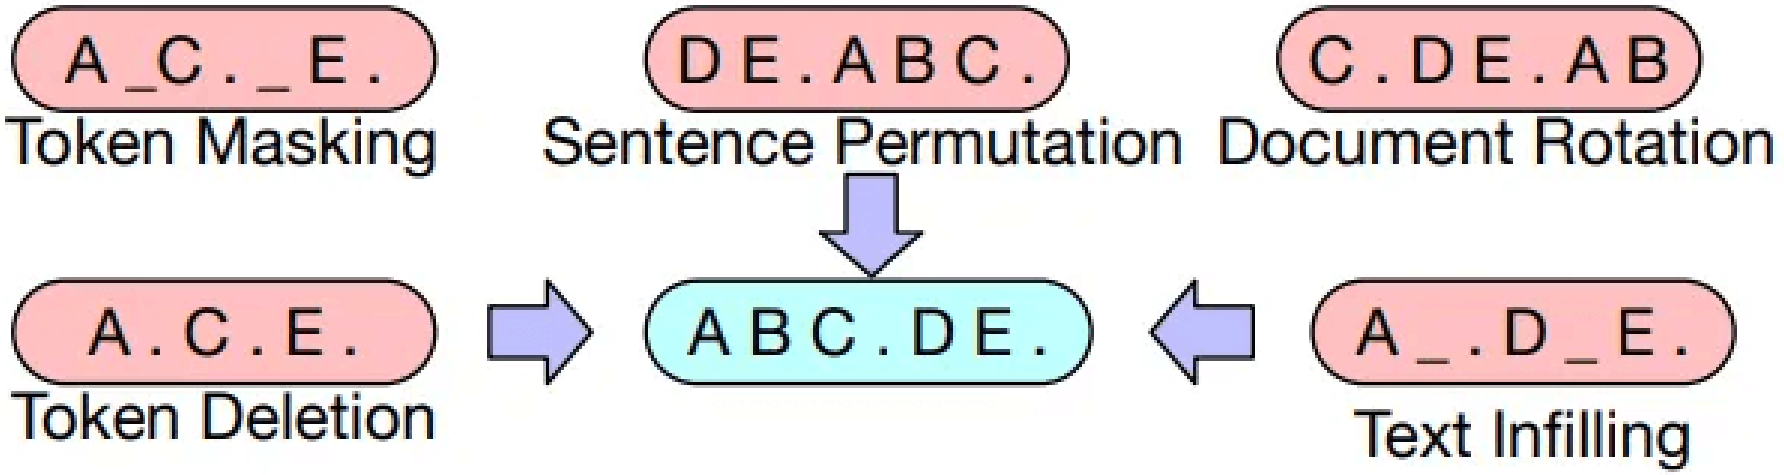

Source : https://medium.com/@zaiinn440/a-comparative-analysis-of-llms-like-bert-bart-and-t5

Préentrainement de modèles : affinage

- Modèles théoriquement déjà utilisables pour de la traduction, mais on fait généralement de l'affinage (*fine-tuning*) sur des données de traduction parallèles pour améliorer les performances.

Préentrainement de modèles : affinage

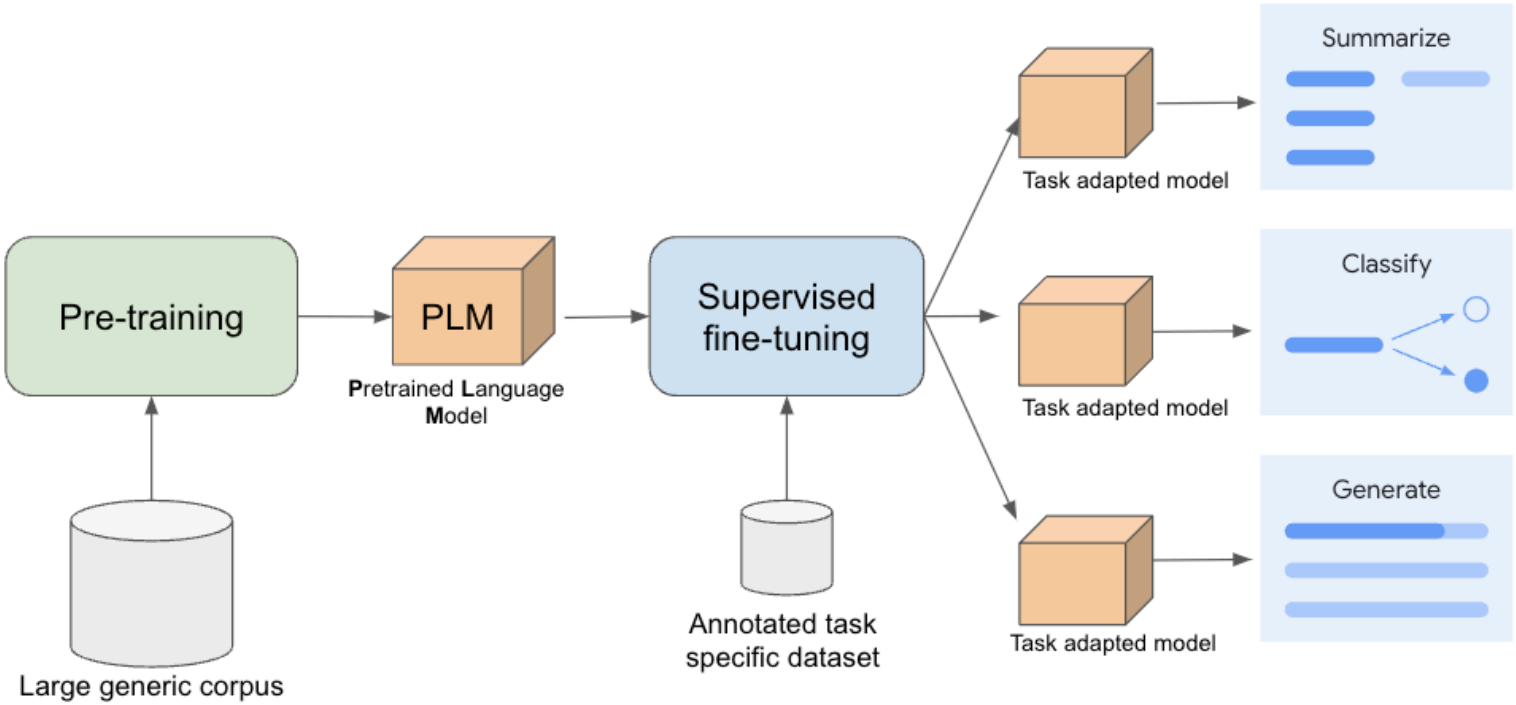

Source : https://cloud.google.com/blog/products/ai-machine-learning/supervised-fine-tuning-for-gemini-llm

T5 (Text-to-Text Transfer Transformer)

- Modèle Transformer séquence-à-séquence préentrainé sur plusieurs tâches.

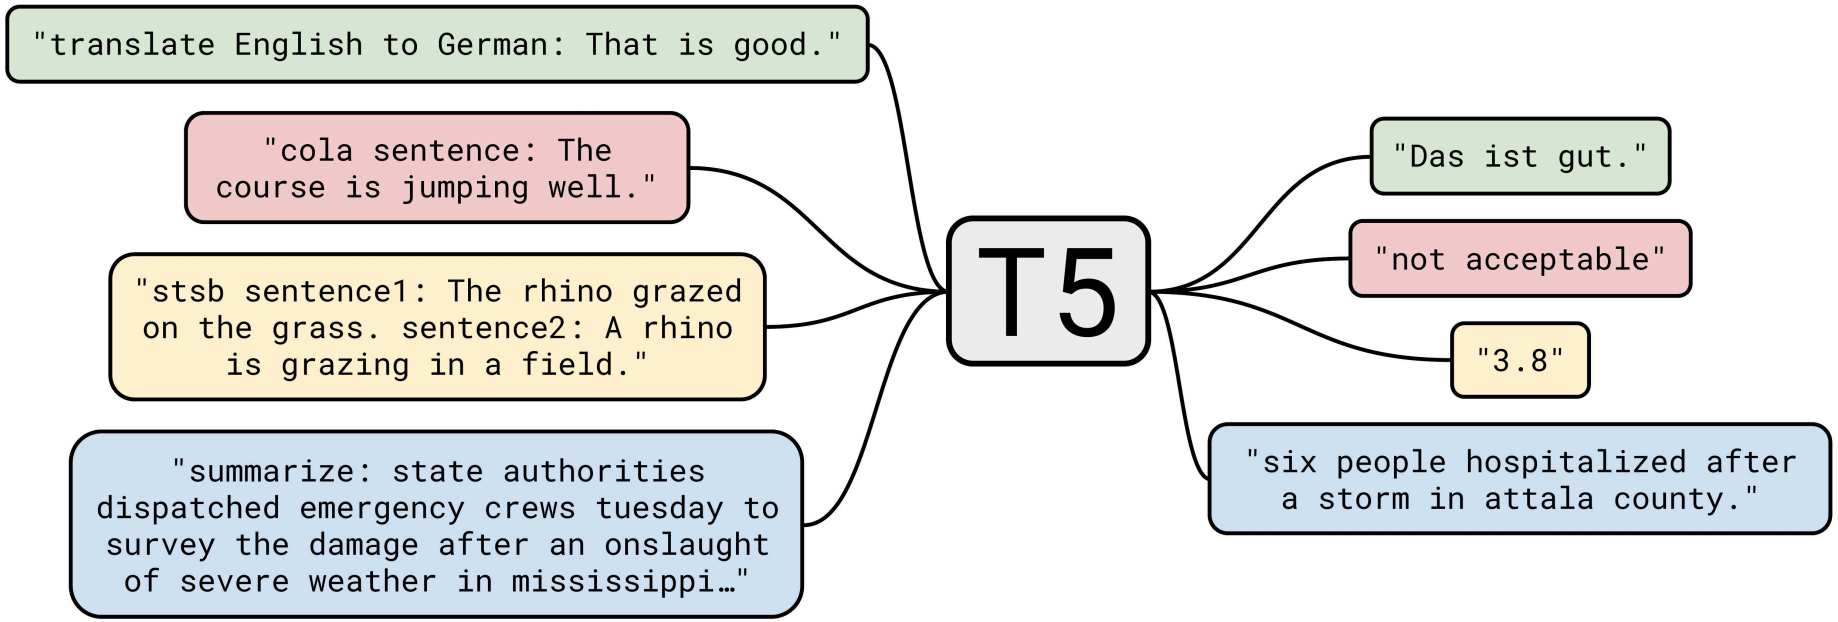

Source : **Raffel et al. (2020)**

T5 (Text-to-Text Transfer Transformer)

- Modèle Transformer séquence-à-séquence préentrainé sur plusieurs tâches.
- Très bonnes performances de base sur de nombreuses tâches (pour un modèle préentrainé), dont la traduction automatique.
- Repose sur du ***prefix-tuning*** : tokens « virtuels » qui conditionnent les réponses du modèle : ce sont en fait des vecteurs appris pendant l'entrainement et utilisés comme paires clé/valeur dans le mécanisme d'attention.
- Les poids du modèle restent inchangés (contrairement à de l'affinage).

Prefix-tuning

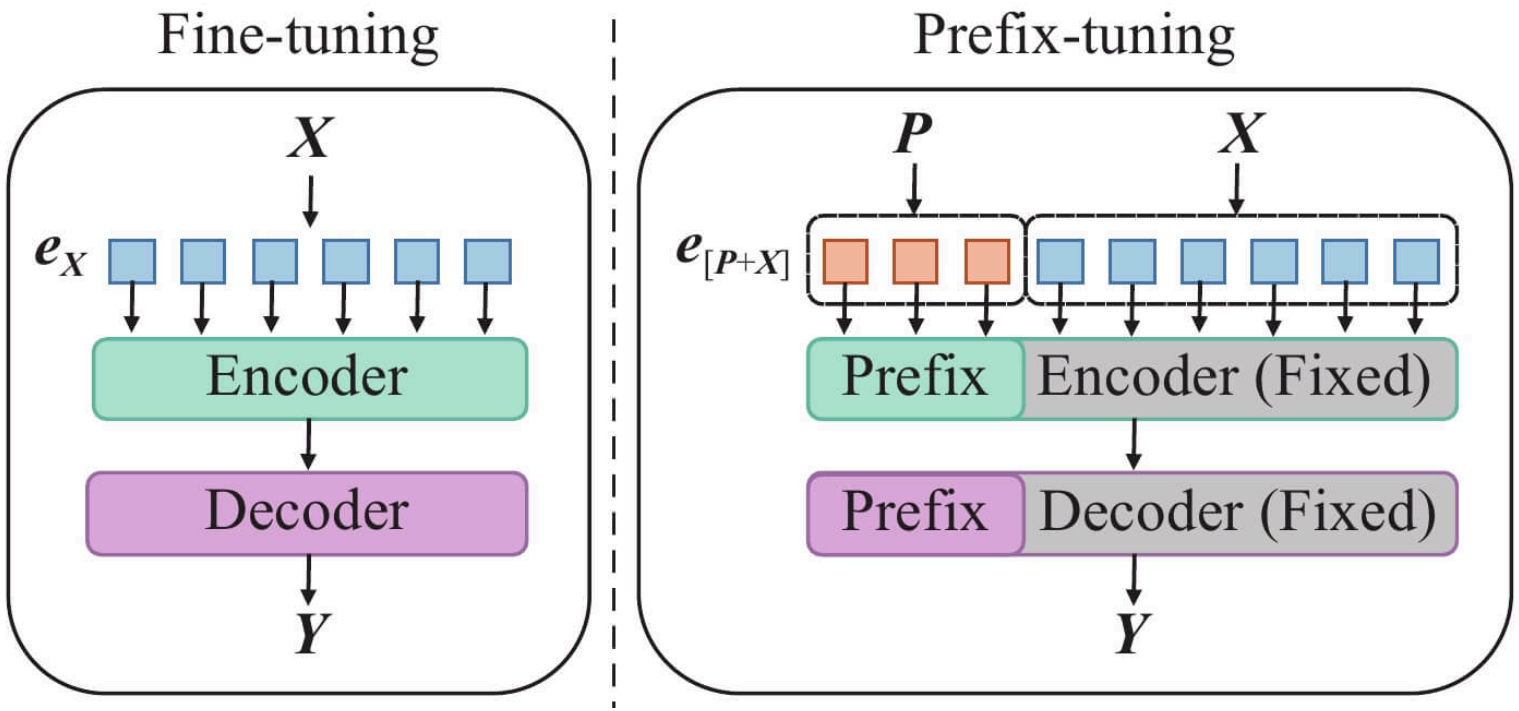

Source : **Chen et al. (2023)**

MarianMT

- Modèle de traduction automatique basé sur l'architecture Transformer, conçu par **Junczys-Dowmunt et al. (2018)**.
- Développé pour être léger et rapide (implémentation en C++), tout en offrant de bonnes performances de traduction.
- Site web : **https://marian-nmt.github.io/**

MarianMT : vitesse d'entrainement

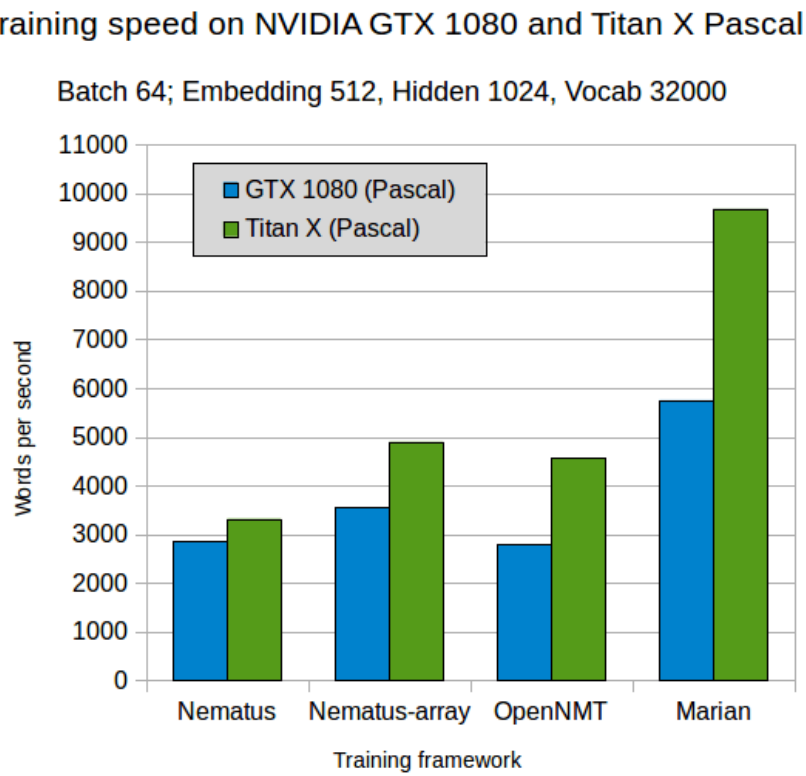

Modèles autorégressifs

- Recours de plus en plus fréquent à des modèles autorégressifs (*Transformer decoder-only*) pour la traduction automatique (GPT-4, Llama 3/4, Qwen, Claude…) en raison de leurs performances de plus en plus élevées pour la tâche.
- Nous aborderons plus en détail ce type de modèle au prochain cours.

III. Mise en pratique

⊕ Ressources complémentaires

- Transformer Explainer
- The Illustrated Transformer
- LLM Visualization
- ⋆ 3Blue1Brown : *Transformers, the tech behind LLMs* ▷
- ⋆ 3Blue1Brown : *Attention in transformers, step-by-step* ▷

Mise en pratique

- Notebook disponible sur Moodle pour l'entrainement d'un modèle Seq2Seq T5 pour de la traduction automatique de l'anglais vers le français.

Bibliographie

Chen, R., Li, F., et Wang, Z. (2023). Prefix-LSDPM: A Few-shot Oriented Online Learning Session Dropout Prediction Model. *Journal of East China University of Science and Technology*, *49*(5), 754-763. **10.14135/j.cnki.1006-3080.20230206003**

Dai, A. M., et Le, Q. V. (novembre 2015). *Semi-Supervised Sequence Learning* (Numéro arXiv:1511.01432). arXiv. **10.48550/arXiv.1511.01432**

Devlin, J., Chang, M.-W., Lee, K., et Toutanova, K. (octobre 2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* (Numéro arXiv:1810.04805). arXiv. **10.48550/arXiv.1810.04805**

Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., Hoang, H., Heafield, K., Neckermann, T., Seide, F., Germann, U., Aji, A. F., Bogoychev, N., Martins, A. F. T., et Birch, A. (avril 2018). *Marian: Fast Neural Machine Translation in C++* (Numéro arXiv:1804.00344). arXiv. **10.48550/arXiv.1804.00344**

Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., et Sutskever, I. (2019). *Language Models Are Unsupervised Multitask Learners*.

Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., et Liu, P. J. (juillet 2020). *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer*.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., et Polosukhin, I. (juin 2017). *Attention Is All You Need* (Numéro arXiv:1706.03762). arXiv. **10.48550/arXiv.1706.03762**